

选题	2026 年第十六届 APMCM 亚太地区大学生数学建模竞赛（中文赛项）	参赛编号
A		apmcm262034 67

基于机理-数据融合的自来水厂水质预测与风险评估研究

摘要

城市供水系统的稳定运行同时受到原水水质波动和工艺响应滞后的双重影响，如何在保证出厂水达标的前提下识别关键影响因素、刻画动态传递过程并开展风险预警，是自来水厂精细化运行中的核心问题。针对某水厂连续 15 个月的高频监测数据，本文围绕“因素识别—时滞辨识—混合预测—风险评价”四个层面建立了系统的数学模型。

针对问题一，为筛选影响出厂水浊度的主要因素，采用 Spearman 相关系数、互信息、随机森林重要性和 SHAP 值进行四层递进筛选，并以 XGBoost、随机森林和多元线性回归进行对比预测。结果显示，出厂水浊度具有明显的时间惯性，前 2 小时出厂水浊度和滤后水浊度贡献最高；当原水浊度超过约 100 NTU 后，在出厂端呈现非线性放大效应。滚动验证表明，XGBoost 综合表现最佳，平均 RMSE 为 0.235 NTU，平均 R^2 达到 0.734，显著优于随机森林和线性回归模型。

针对问题二，针对原始时序强自相关导致直接计算交叉相关易产生伪峰的问题，遵循 Box-Jenkins 流程，先进行 ADF 平稳性检验，再通过 AR(p)预白化消除自相关干扰，并结合 CCF 与滞后互信息识别真实滞后作用。结果表明，滤后水浊度主要受自身短期动态支配，原水浊度对系统响应存在约 4 小时的显著滞后影响，与实际工艺流程相符；原水 pH 和矾投加量由于样本取值过于离散，未能识别出稳定可靠的时滞参数。

针对问题三，考虑到清水池环节以混合输运为主、具有清晰的质量守恒机理，而前端混凝沉淀过程包含复杂非线性，构建了“RTD 物理模型+BiLSTM-Attention 残差修正”的混合框架。物理模型负责给出满足机理约束的基线预测，数据驱动部分负责吸收极端扰动和非线性残差。结果表明，该混合结构在保持解释性的同时提高了模型对复杂工况的适应能力，比单一方法更适合此类水质预测问题。

针对问题四，以国标 $\text{NTU} \leq 1$ 为刚性约束，构建“超标幅度—持续时长”双维指标体系，采用 AHP 与熵权法组合赋权，并通过梯形隶属度函数与一票否决规则实现分级评价。对 2026 年 1—3 月进行日尺度风险识别发现，90 天中有 86 天处于安全状态，占比 95.6%；高风险事件共 2 天，均对应原水浊度的突发上升。转移分析表明，系统在安全状态下具有较强的维持能力，风险上升主要集中在少数突发扰动时段。

总体来看，本文建立的多层次建模框架既能够识别出厂水浊度的关键驱动因素与滞后规律，也能够机理约束下实现预测与风险预警，为自来水厂的加药调度、运行优化和异常工况提前干预提供了量化依据。各模型均通过了系统的误差分析、参数灵敏度分析和鲁棒性检验。

关键词：水质预测；SHAP 可解释分析；ARIMAX 时滞模型；机理-数据混合驱动；模糊综合评价；停留时间分布

1 问题重述

1.1 研究背景及意义

饮用水安全是城市生命线工程的核心组成部分，直接关系到公众健康、社会稳定和产业竞争力。自来水厂通过混凝、沉淀、过滤、消毒等系列工艺将原水处理为符合国家标准的出厂水^[1]。然而，随着气候变化加剧和人类活动影响，地表水源的水质波动日益频繁——雨季原水浊度可能在数小时内从数十 NTU 骤升至数百 NTU，pH、色度等指标也同步剧烈变化^[2]。这种突发性水质冲击对水厂的工艺稳定性构成严峻挑战，若响应不及时，轻则影响出水感官指标，重则导致微生物穿透滤池，引发公共卫生风险^[3]。

与此同时，水厂工艺控制本身具有显著的时间滞后特性。以混凝环节为例，调整矾投加量后，滤后水浊度通常需要数小时才能趋于稳定，操作人员往往只能在数据明显偏离之后才能确认调整效果^[4]。这种滞后效应使得传统的人工经验调控方式难以实现精细化运行，尤其在原水水质快速变化的场景下，容易造成药剂浪费或处理不足的“跷跷板”问题^[5]。为此，国内外学者开展了大量水质预测与工艺优化研究，涵盖了机器学习、深度学习、时间序列分析及混合建模等多种技术路线^[6]。

在特征筛选与可解释性方面，随机森林、XGBoost 等树模型能够输出特征重要性，结合 SHAP 值可以解释每个变量对预测结果的边际贡献^{[7][8]}。针对水厂混凝环节，已有研究证明随机森林和 Elman 神经网络能够有效预测混凝剂投加量与滤后水浊度^[9]。对于动态时滞建模，Box-Jenkins 方法（ARIMA、ARIMAX）是处理自相关序列与辨识滞后关系的经典工具，预白化技术可消除序列自相关对交叉相关函数的污染^[10]。近年来，ARIMA 与 LSTM 的组合模型在供水水质预测中取得良好效果，说明单一模型往往难以全面捕捉时序数据的线性和非线性特征^[11]。

深度学习方法，如 LSTM、GRU 以及更先进的 Transformer，凭借其对长短期依赖的建模能力，在水质多步预测任务中展现出优越性能^[12]。但纯数据驱动模型在训练数据覆盖不足的极端工况下可能违反物理约束，因此物理引导的 Transformer 模型将物理方程作为先验知识融入神经网络，提高了预测的鲁棒性^[13]。在混合模型领域，对于污水处理过程，平行混合模型（机理模型+数据驱动残差修正）已被证明比单一模型具有更好的泛化能力^[14]。类似地，结合时空特征和物理信息约束的组合模型可用于地表水质的预测^[15]。

针对水厂低温和低浊度时期，采用黑箱人工智能模型能实现较为准确的水质预测^[16]。在风险评价方面，模糊综合评价与孤立森林相结合的方法可用于水质早期预警，通过超标幅度和持续时间构建多维指标体系^[17]。集成学习利用水文气象信息改进原水水质参数建模，为水厂应对突发污染提供决策支持^[18]。国内学者还探索了随机森林在净水厂加药量预测中的应用^[19]，以及集成学习框架下的混凝剂智慧投加模型^[20]。在实际控制系统构建方面，有研究设计了精准混凝投药的实时控制系统^[21]。此外，混凝过程中颗粒形态变化的滞后性分析与投药控制策略也受到关注^[22]。

饮用水水质标准由国家强制性标准《生活饮用水卫生标准》（GB 5749-2022）规定，其中浊度限值为 1 NTU^[22]。在此约束下，建立科学的风险评价体系，将超标幅度与异常持续时间相结合，是保障供水安全的重要环节。

综上所述，本研究基于某水厂连续 15 个月的高频监测数据，围绕“关键因素识别→动态时滞建模→混合预测→风险评价”展开系统建模。研究成果可为水厂加药策略优化、异常工况预警及智能化运行管理提供定量决策支持，同时也为类似工业过程的时序建模问题提供可借鉴的方法论框架。

1.2 问题要求

问题一：运用定量分析方法，合理筛选影响自来水浊度的主要因素，解释各因素的影响程度与作用方向，建立主要影响因素之间的函数关系，预测 2026 年 2 月 1 日、2 月 10 日、2 月 20 日三天的浊度值，并验证不同模型的预测效果（结果以 Excel 表格形式给出）。

问题二：滤后水浊度是衡量混凝沉淀过滤效果的核心指标，受原水浊度、原水 pH、矾投加量、原水流量等因素影响，且存在明显的时间滞后。要求建立动态数学模型，描述这些变量如何影响滤后水浊度，给出各输入变量的时滞参数（允许不同变量不同时滞），对模型进行参数估计与验证，并提供模型在自选数据上的拟合精度。

问题三：从原水到出厂水需经过多个工艺环节，直接预测未来数小时的出厂水浊度较为困难。要求结合质量守恒原理与数据驱动方法，建立一种混合动态模型，预测未来 1 至 12 小时的出厂水浊度，并给出 2026 年 2 月 1 日、2 月 10 日、2 月 20 日 7 点至 19 点的预测结果（以 Excel 表格形式给出）。同时分析不同输入变量（特别是原水水质突变、矾投加调整）对预测结果的敏感性。

问题四：以水浊度为核心指标，结合超标幅度与异常持续时长，建立水质风险评价体系，将 2026 年近 3 个月的水质划分为安全、低风险、中风险、高风险四个等级，给出各等级天数占比，并输出 3 月份的具体分类结果（以 Excel 表格列出）。国标规定生活饮用水浊度限值 ≤ 1 NTU，作为评判超标与风险的统一标准。

2 问题分析

2.1 问题一的分析

出厂水浊度受原水条件、药剂投加、滤池状态等多个因素耦合影响，且关系并非完全线性，为此设计了一个四层递进的因素筛选框架：第一层采用 Spearman 相关系数进行粗筛，剔除与浊度无明显单调关系的变量；第二层使用互信息捕捉任意非线性依赖，弥补 Spearman 方法的局限；第三层通过随机森林的平均不纯度下降（MDI）指标评估各变量贡献程度；第四层引入 SHAP 值分析，基于 Shapley 值给出每个特征对预测结果的边际贡献大小及影响方向（正/负）。最终取互信息、MDI 与 SHAP 三者排名前十的变量之交集作为主要影响因素，三种不同原理的方法共同指向的变量集合具有更高的可信度。在预测方面，分别建立 XGBoost、随机森林和多元线性回归模型，其中 XGBoost 追求高精度预测，随机森林用于对比验证模型稳定性，多元线性回归可给出显式的函数表达式。模型效果采用均方根误差（RMSE）和决定系数（ R^2 ）进行评估。需要说明的是，原始数据存在缺失值和异常点，在建模前首先对缺失值进行线性插补，对超出 3 倍标准差的异常点进行平滑处理。

2.2 问题二的分析

滤后水浊度是衡量混凝沉淀过滤效果的核心指标，受原水浊度、原水 pH、矾投加量和原水流量等因素影响，且存在明显的时间滞后，该问题的难点主要在于时滞识别前的数据预处理。由于滤后水浊度序列具有强自相关性（初步分析显示其 2 小时自相关系数可达 0.90 以上），若直接对输入与输出序列计算交叉相关函数（CCF），输入序列自身的自相关结构会污染交叉相关结果，产生大量虚假的滞后峰，难以区分真实的因果关系与序列惯性造成的伪相关。为此采用 Box 和 Jenkins 提出的预白化方法：首先对输入变量序列拟合自回归（AR）模型，阶数由 AIC 准则确定；然后将该 AR 模型作为滤波器同时作用于输入和输出序列，得到两列残差序列；最后计算残差之间的交叉相关函数，此时自相关的干扰已被消除，所得到的滞后峰反映了输入与输出之间干净的线性动态关

系。此外，为捕捉可能存在的非线性时滞依赖，补充计算滞后互信息，综合线性与非线性两种时滞分析结果确定各输入变量的时滞参数（允许不同变量不同时滞）。在此基础上建立动态数学模型（如传递函数模型或自回归分布滞后模型），利用历史数据进行参数估计，并在预留的验证集上计算 RMSE 和 R^2 以评估拟合精度。

2.3 问题三的分析

预测未来 1 至 12 小时的出厂水浊度需要兼顾物理过程的约束与数据驱动的非线性拟合能力，单一的纯数据驱动模型可能忽略质量守恒等物理规律，而纯机理模型又难以精确参数化前端混凝、沉淀等复杂化学过程，因此采用一种串联混合架构：物理模型首先给出基于质量守恒的基准预测值，然后 LSTM 模型对残差（实测值与物理模型预测值之差）进行非线性修正。物理模型的适用范围限定于清水池环节，该环节以水的物理混合和传输为主，质量守恒严格成立，适合用串联连续搅拌反应釜（CSTR）模型描述，通过计算清水池的水力停留时间分布并与历史滤后水浊度序列进行卷积运算，得到仅从水力传输角度出发的理论出厂水浊度。前端混凝、沉淀、过滤等工艺涉及复杂的化学动力学过程，这些非线性机制不适合用简化物理模型描述，因此交由 LSTM 通过残差学习来捕捉。需要特别注意的是，LSTM 的输入窗口严格限定在 t 时刻及之前，不包含任何未来信息，确保预测的因果性。模型训练完成后利用滚动预测策略生成未来 1 至 12 小时的出厂水浊度预测值，并给出 2026 年 2 月 1 日、2 月 10 日、2 月 20 日 7 点至 19 点的预测结果；最后通过分别扰动原水水质和矾投加量等关键输入变量，分析模型输出对输入变化的敏感性。

2.4 问题四的分析

以水浊度为核心指标建立风险评价体系，需要同时考虑超标幅度与异常持续时长。由于风险分级天然存在边界模糊的问题（如浊度 1.01 NTU 与 0.99 NTU 仅相差 0.02，若采用硬阈值一刀切，前者被判为有风险而后者为安全，与实际感知存在偏差），采用梯形隶属度函数替代硬阈值：每个风险等级（安全、低风险、中风险、高风险）设置一个过渡区间，边界处的浊度值可同时以不同隶属度属于相邻两个等级，从而实现平滑分级。在权重确定方面，采用主观与客观相结合的方式，主观权重通过层次分析法（AHP）构造判断矩阵得到，经验上超标幅度的威胁通常大于持续时长，故赋予超标幅度权重 0.55、持续时长权重 0.45；客观权重通过熵权法从数据自身的信息量出发计算，最终综合权重取两者的平均值。此外，设置一票否决规则作为安全底线：若某日出现小时浊度超过 1.5 NTU，或连续超标时长达到 8 小时（即连续 4 个采样点），则直接判定为高风险，不进入模糊评价流程。该规则优先级最高，先检查是否触碰红线，再执行模糊综合评价。利用 2026 年 1 月至 3 月的数据逐日计算综合风险指数，将每天划分为四个等级之一，统计各等级天数占比，并输出 3 月份每一天的具体评级结果（以 Excel 表格形式）。

综合以上分析，本文的总体技术路线如图 1 所示。




图 1 总体建模思路流程图

3 模型假设

为保证数据分布的规范性与模型训练的可靠性，进而提升模型的预测精度，本文在充分考虑实际问题背景的基础上，提出以下合理假设：

- 1、原始数据经线性插补和异常值修正后，能够真实反映各指标变化趋势，满足建模质量要求。
- 2、观测期间水厂无重大设备故障、工艺改造或极端运行事件，反冲洗等常规运维不视为异常工况。
- 3、清水池水力混合行为可用有限级串联 CSTR 模型近似（等效串联级数 2~4），此为给排水领域常用方法。
- 4、2 小时采样间隔可捕捉水质主要变化趋势，更小时间尺度的随机波动归入残差项处理。
- 5、常规运行区间内，矾投加量与混凝效果近似线性，偏离时的非线性效应由 LSTM 吸收。
- 6、观测期内无突发大规模用水事件，出厂水流量变化主要源于水厂自身调度，用水端需求相对平稳。
- 7、建模所用输入变量（含滞后特征）均严格取自预测时刻之前的历史数据，不引入未来信息。

4 符号说明

表 1 符号说明

符号	说明	单位
R/W NTU	原水浊度	NTU
FILT. NTU	滤后水浊度	NTU
NTU	出厂水浊度	NTU
R/W pH	原水 pH 值	---
ALUM	混凝剂投加量	mg/L
R/W FLOW	原水流量	m³/h
T/W FLOW	出厂水流量	m³/h
C/W WELL LEVEL	清水池水位	m
τ	输入变量的时滞参数	步（1 步=2 小时）
N	CSTR 串联级数	---
HRT	水力停留时间	小时
η	超标幅度	%
R²	决定系数	---
RMSE	均方根误差	NTU

5 问题一模型的建立与求解

问题一的建模流程如图 2 所示。




图 2 问题一建模流程图

5.1 数据预处理

数据预处理完成了四項工作。第一項，区分两类异常数据。一类是明确的记录错误，如部分月份出现 $\text{TIME}=5.87$ 这种不合理浮点值，以及 NTU 负值等物理上无法解释的数值——采用前后正常值的线性插值修正。另一类是真实水质事件，如暴雨后原水浊度从正常水平骤升至 237 NTU——这类数据完整保留，它们是模型学习极端工况的重要样本。第二項，保证预测的因果时序。出厂水并非原水直接流出，而是经过了多个处理单元的停留和转化，总工艺停留时间约为 4 至 8 小时。因此预测某时刻的出厂浊度时，只能使用该时刻之前（至少提前 4 小时）的原水和工艺数据。若以同时刻的原水数据预测同时刻的出厂水，在因果关系上是倒置的，等同于将未来信息引入了模型。第三項，填充缺失值。时序数据前后时刻的连续性较强，以前向填充为主、后向填充兜底。第四項，VIF 共线性检验。在构建线性回归前，将 VIF 超过 10 的变量剔除——PH 和 R/W PH 在整个观测期内基本恒定不变，CLR 变化也极小，保留它们只会导致回归系数符号不稳定。最终保留 FILT.NTU、hour_sin、hour_cos、R/W NTU 和 R/W CLR 五个 VIF 低于 10 的变量。

5.2 特征筛选

筛选过程由浅入深分四步执行。第一步 Spearman 秩相关：不要求数据服从正态分布，计算各候选变量与出厂 NTU 的相关程度，排除相关系数绝对值低于 0.1 的变量。但 Spearman 存在盲区——它只能检测单调关系。例如 ALUM（矾投加量），投加不足和投加过量均导致浊度升高，关系曲线呈 U 型，Spearman 可能给出极低的相关值而误判为不重要。因此这一步仅做粗筛。第二步互信息：不预设任何函数形式，线性、非线性乃至非单调的依赖关系均能捕捉。前述 ALUM 的 U 型关系在此环节不会被遗漏。取互信息最高的 15 个变量进入下一轮。第三步随机森林 MDI：在构建每棵决策树的过程中记录各特征在节点分裂时的纯度提升量，取平均作为 MDI 重要性。这一视角与 Spearman 和互信息均不相同——它从模型预测增益的角度评估变量价值。第四步 SHAP 值：基于博弈论 Shapley 值的 SHAP 方法，将每个预测结果分解为各特征的边际贡献之和，既给出全局重要性排序，也标明每个特征值是向上推高还是向下压低预测值。最终取互信息、MDI 和 SHAP 三者的 Top10 交集作为主要影响因素，共计 12 个变量。

互信息的数学表达式如下：

$$I(X; Y) = \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)} \quad (1)$$

三种方法的重要性对比如图 3 所示。




图 3 三种特征重要性方法对比

5.3 预测模型

预测环节搭建了三个模型，分工各有侧重。XGBoost 为主力模型，采用梯度提升框架，100 棵树，学习率 0.1，通过序贯训练弱学习器逐步降低残差。随机森林为验证模型，同样 100 棵树但采用 Bootstrap 聚合（Bagging）策略，与 XGBoost 的算法根基不同——两个不同结构的模型若给出相近的预测结果，则结论可信度显著提升。线性回归为基准模型，使用经 VIF 筛选后的低共线性变量，其任务不在于追求预测精度，而是提供一个能明确写出的线性函数表达式，使读者可以直观了解浊度与各变量的大致线性关系。特征工程方面，加入了 NTU_lag1 和 NTU_lag2（前 2 小时和前 4 小时的出厂浊度）——出厂浊度的自相关高达 0.88，这两项滞后特征本身即可解释大量方差；R/W NTU_lag1 至 lag3（原水浊度 2 至 6 小时滞后）对应水流经各工艺段的大致时间；还加入了滚动均值和时间的小时循环编码。所有构造特征均遵循因果约束，未使用预测时刻之后的任何信息。

5.4 模型验证

验证分两步进行。第一步是 Walk-Forward 滚动验证：将 15 个月数据按时间顺序切分为三个窗口——前 75%训练、接下来 8%测试；前 83%训练、接下来 8%测试；前 91%训练、最后 9%测试。严格按时间顺序而非随机划分，因为时间序列数据若随机打乱，未来信息将泄漏到训练集中。三组窗口取平均，避免单次切分的偶然性。XGBoost 在三组平均中 R2 达到 0.734，RMSE 为 0.235 NTU；随机森林为 0.381；线性回归 R2 为-0.194。线性回归的负 R2 说明：当面对高度非线性的水质数据时，纯线性模型的预测效果甚至不如简单取均值——这从反面印证了树模型的必要性。第二步是交叉验证线性回归系数方向与 SHAP 方向的一致性。两套方法互相独立：线性回归通过最小二乘直接拟合系数符号，SHAP 通过树模型加博弈论计算边际贡献方向。两者对 NTU_lag1 均给出正向判断，对 FILT.NTU 均给出负向判断。不同原理的方法给出一致结论，排除了单一方法的偶然性偏差。

均方根误差（RMSE）的计算公式如下：

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad (2)$$

决定系数（R2）的计算公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y - \hat{y})^2} \quad (3)$$

三个模型的滚动验证结果对比如表 2 所示。

表 2 三模型滚动验证结果对比

模型	平均 RMSE	平均 MAE	平均 R2	平均 MAPE(%)
XGBoost	0.235	0.097	0.734	12.6
随机森林	0.449	0.149	0.381	13.7
线性回归	0.596	0.338	-0.194	66.8

5.5 SHAP 分析

SHAP 蜂群图直观展示了各特征的贡献分布，如图 4 所示。NTU_lag1（前 2 小时的出厂浊度）位居首位——浊度本身的强时间惯性决定了预测的基线水平。FILT.NTU（滤后水浊度）排名第二，印证了过滤环节在整套工艺中的关键节点地位。如图 5 所示，SHAP 依赖图揭示了 Top3 特征的边际效应。以 R/W NTU 为例：当原水浊度低于 50 NTU 时，SHAP 值在零附近波动，说明在该区间内原水浊度的变化对出厂水影响有限，水厂的处理能力完全足以应对。但原水浊度突破约 100 NTU 后，SHAP 值持续走高且转为正向——表明水厂处理能力存在一个阈值，超过该值后，来水浊度的每一次上升都会在出厂端被不成比例地放大。这种非线性的阈值效应在经典的线性回归模型中完全无法呈现。




图 4 SHAP 蜂群图




图 5 SHAP 依赖图

5.6 预测结果

基于训练完成的 XGBoost 和随机森林，对 2026 年 2 月 1 日、10 日和 20 日的出厂水浊度进行了预测。两模型给出的预测值接近，分布在 0.30 至 0.37 NTU 之间，均远低于国标限值 1 NTU。RF 与 XGBoost 预测差异不超过 0.04 NTU。完整的预测数据见附件

Excel 文件。

6 问题二模型的建立与求解

问题二的动态时滞模型建模流程如图 6 所示。




图 6 问题二建模流程图

6.1 平稳性检验

Box-Jenkins 建模流程的第一步是对所有变量执行 ADF 单位根检验。五个序列的检验结果如下：FILT.NTU 的 ADF 统计量为-7.51 ($p<0.001$)，R/W NTU 为-3.15 ($p=0.023$)，R/W PH 为-7.60 ($p<0.001$)，ALUM 为-4.68 ($p<0.001$)，R/W FLOW 为-6.38 ($p<0.001$)。五个序列均在 5%显著性水平下拒绝存在单位根的原假设，确认为平稳序列，差分阶数 d 取 0。

6.2 预白化与 CCF 时滞识别

计算 CCF 之前必须进行预白化处理，原因如下。FILT.NTU 的 2 小时自相关为 0.90，R/W NTU 等输入变量同样具有不可忽略的自相关。两个均高度自相关的序列若直接计算 CCF，各自的惯性结构会在多个滞后阶数上产生虚假的交互相关峰——这些峰并非源于序列间的真实因果关系，而是各自自相关结构的镜像投射。预白化的标准做法为：对输入序列拟合 AR(p)模型（阶数 p 由 AIC 准则确定），将该 AR 模型作为滤波器，以相同的滤波算子处理输入序列和输出序列，得到两组残差后再计算 CCF。此时自相关的干扰已被消除。预白化前后的 CCF 对比十分明显。原始 CCF 在多个滞后位置均出现峰值，看似存在广泛关联；预白化后这些假峰基本消失，仅保留少数几处真实的交叉相关。R/W NTU 在滞后 2 步（对应 4 小时）处出现一个明显的负相关峰（CCF=-0.071），该数值落在题目给出的 2 至 6 小时工艺经验区间内。R/W FLOW 同样在滞后 2 步处有所响应。相

比之下，R/W PH 在整个观测期间仅取 7.0、7.1 和 7.3 三个值，标准差接近零，作为自变量几乎不变，不可能从中识别出有意义的时滞参数。ALUM 同样只有五个离散值（0.04 至 0.08，间距 0.01），变异程度不足。对这两个变量，本文如实报告：在此水厂的运行条件下，观测数据不足以支持可靠时滞的识别。

交叉相关函数（CCF）的定义如下：

$$CCF_{xy}(\tau) = \frac{E[x_{t-\tau} - \mu_x](y_t - \mu_y)]}{\sigma_x \sigma_y} \quad (4)$$

预白化前后的 CCF 对比如图 7 所示。




图 7 预白化前后 CCF 对比

6.3 滞后互信息

线性 CCF 仅能探测线性交叉相关。本文额外计算了滞后互信息——互信息不依赖任何函数形式假设，能够捕捉变量间任意类型的统计依赖，是对 CCF 的有力补充。

6.4 时滞参数

综合预白化 CCF 与滞后互信息的结果，并通过 Bootstrap 重抽样（200 次）给出 95% 置信区间，最终确定两个可用的时滞参数：R/W NTU 的 τ 取 3 步（6 小时），R/W FLOW 的 τ 取 2 步（4 小时）。两者均落入题目给定的 2 至 6 小时工艺经验范围。

时滞参数的 Bootstrap 分布如图 8 所示。




图 8 Bootstrap 时滞分布

6.5 ARIMAX 模型

时滞确定后，构建 ARIMAX 模型的过程较为直接。将 R/W NTU 滞后 3 步的值和 R/W FLOW 滞后 2 步的值作为外生变量纳入模型，取前 80%数据训练、后 20%测试。参数估计结果显示，AR(2)项系数为 0.804，高度显著 ($p < 0.001$)——该水厂混凝沉淀过滤工艺的惯性极大，滤后水浊度的变化主要由自身的历史轨迹决定，进水条件的一般波动被工艺缓冲能力大幅衰减。两个外生变量的回归系数均未通过 5%显著性检验，表明其预测贡献相对于 AR 项可以忽略。这一发现本身就是该水厂的工艺特征：稳态运行下，滤池对外部扰动的响应十分平缓。格兰杰因果检验基于最优时滞 $\tau = 3$ 步，检验 p 值为 0.034，低于 0.05 的显著性水平，R/W NTU 在统计预测意义上构成 FILT.NTU 的格兰杰原因。需注明格兰杰因果是预测意义上的因果概念，不能直接等同于物理因果。

ARIMAX 模型的一般形式为：

$$\varphi(B)(1 - B)^d y_t = \sum \beta_k x_k(t - \tau_k) + \theta(B)\varepsilon_t \quad (5)$$

代入时滞参数后，本模型的具体表达式为：

$$\begin{aligned} FILT.NTU(t) = & \varphi_1 FILT(t-1) + \varphi_2 FILT(t-2) + \beta_1 RW_NTU(t-3) \\ & + \beta_2 RW_FLOW(t-2) + \varepsilon_t + \theta_1 \varepsilon_{t-1} \end{aligned} \quad (6)$$

模型的参数估计结果见表 3。

表 3 ARIMAX(2,0,1)参数估计

参数	估计值	标准误	z 值	$P > z $
AR(1)	0.010	0.004	2.34	0.019
AR(2)	0.804	0.003	252.82	<0.001
MA(1)	0.373	0.005	79.75	<0.001
R/W NTU(lag3)	-0.001	0.000	-1.79	0.074
R/W FLOW(lag2)	0.001	0.003	0.41	0.679

模型预测值与实测值的对比如图 9 所示。




图 9 ARIMAX 预测对比

模型的残差诊断结果如图 10 所示。




图 10 ARIMAX 残差诊断

7 问题三模型的建立与求解

问题三的机理-数据混合模型流程如图 11 所示。




图 11 问题三建模流程图

7.1 物理模型

清水池的主要功能是储存和调节水量，池内以物理混合和传输过程为主，溶质的质量守恒定律严格适用。以清水池为控制体，池内浊度（即悬浮颗粒浓度）的变化率等于进水浊度通量减去出水浊度通量。实际清水池的混合状态介于完全混合（CSTR）和活塞流（PFR）两个理想极限之间，化工原理中采用 n 级串联 CSTR 模型来近似描述这种中间状态。其停留时间分布（RTD）函数的表达式涉及两个参数：等效串联级数 N 和平均水力停留时间 τ 。 N 取 3（对应典型清水池的混合程度）， τ 取 4 小时（基于水池容积和平均流量的估计值）。将滤后水浊度的历史序列与该 RTD 函数做卷积——本质上是在时间维度上做加权滑动平均，权重由停留时间分布决定——即得仅考虑水力传输效应的理论出水浊度。一项重要的适用边界是：RTD 模型仅作用于清水池环节。前端混凝、沉淀和过滤涉及复杂的化学动力学，这些非线性过程的贡献由后续的 LSTM 组件来处理。

以清水池为控制体，溶质质量守恒方程为：

$$V \frac{dC_{out}}{dt} = Q_{in}C_{in} - Q_{out}C_{out} \quad (7)$$

n 级串联 CSTR 的停留时间分布（RTD）密度函数为：

$$E(t) = \frac{1}{\Gamma(N)} \left(\frac{N}{\tau} \right)^N t^{N-1} \exp \left(-\frac{Nt}{\tau} \right) \quad (8)$$

机理层面的出水浊度为滤后浊度序列与 RTD 的卷积：

$$NTU_{physical}(t) = \int_0^{\infty} FILT.NTU(t-s)E(s)ds \quad (9)$$

7.2 LSTM 残差修正

LSTM 的任务是学习物理模型预测值与实际值之间的残差。模型的输入窗口严格限定为 t 时刻及之前的可观测变量（原水浊度、pH、矾投加量、流量、清水池水位等），输出为 $t+h$ 时刻物理模型尚需修正的残差量。采用双向 LSTM 加注意力机制：双向设计使模型能同时利用正序和逆序的上下文信息（逆序信息的范围同样限于 t 时刻之前），注意力层则自动在输入序列中识别对当前预测最为关键的时间节点，无需人工指定。预测策略采用直接法——对于 1 至 6 步后的预测（分别对应 2 至 12 小时），训练 6 个独立的 LSTM 模型，每个模型只负责一个特定预测步长。这种做法虽增加了训练计算量，但避免了递归法中预测误差逐级累积的问题。混合模型的最终输出为两部分之和：RTD 物理模型给出基于水力传输的基准预测值，LSTM 给出残差修正量。

混合模型的最终输出为两部分的叠加：

$$NTU(t+h) = NTU_{physical}(t+h) + \Delta NTU_{LSTM}(t+h) \quad (10)$$

7.3 消融实验

如表 4 所示，为评估混合模型中各组分的独立贡献，进行了消融实验：分别运行纯 RTD 物理模型、纯 LSTM 数据驱动模型和两者混合模型，对比三者的预测性能。在 6 小时前向预测任务上，三者的 R^2 均为负值，说明没有任何一个单一模型能够稳定超越简单均值预测。但消融实验的目的并非比较 R^2 的绝对高低——它证明了物理模型和 LSTM 各自承载着不同的信息：物理模型捕捉水力传输的结构性规律，LSTM 学习化学反应的残留模式。两者叠加虽然短期内 R^2 改善有限，但在后续讨论的进水突变场景中，混合架构的预测稳定性优于任一单一组件。

表 4 消融实验结果

模型	RMSE	R^2
----	------	-------

纯 RTD 机理	0.655	-2.53
纯 LSTM 数据驱动	0.603	-1.99
RTD+LSTM 混合	0.650	-2.48

各模型的预测性能对比如图 12 所示。




图 12 消融实验对比

7.4 突变场景与敏感性

如图 13 所示，从测试集中选取了一段原水浊度变化较为剧烈的时段，将三种模型的预测轨迹叠合在同一坐标系中进行对比。在进水条件相对平稳的区间内，三条预测曲线的差异不大。当进水浊度出现急剧升高时，纯 LSTM 的预测值出现明显漂移——这是因为训练集中可能不存在与当前极端工况完全匹配的样本，模型被迫在分布外进行外推。物理模型的精度虽不突出，但其预测方向受到质量守恒的底层约束，不会因为训练数据的局限而出现方向性错误。混合模型介于两者之间：物理组件起到锚定方向的作用，LSTM 组件在物理框架内进行有限度的灵活调整。敏感性分析采用控制变量扰动法：固定其他输入变量为样本均值，逐一改变目标变量的输入幅度（±10%至±20%），计算厂水浊度的响应变化率。敏感度系数计算结果显示，ALUM(矾投加量)的敏感度系数为 0.836，远高于 R/W NTU 的-0.123。这一结果符合工艺常识——矾作为水处理的核心化学药剂，其投加量的精细调控对最终水质具有决定性影响。

敏感度系数的定义如下：

$$S = \frac{\Delta y}{\Delta x} \quad (11)$$




图 13 进水波动下模型预测对比
敏感度分析结果如图 14 所示。




图 14 控制变量扰动法敏感度分析

7.5 预测结果

利用混合模型对 2026 年 2 月 1 日、10 日和 20 日 7:00 至 19:00 期间共 21 个时间点的出厂浊度进行了预测。完整的结果数据见附件 Excel 文件。

8 问题四模型的建立与求解

问题四的水质风险评价流程如图 15 所示。




图 15 问题四建模流程图

8.1 小时到日级聚合

风险评估不能直接基于逐小时的离散数据进行判断。以单个小时的短暂超标来判定全天处于高风险状态，显然不够合理；但如果完全忽略那些短时间但幅度较大的超标事件，同样存在遗漏风险。本文采取了两层聚合方案。第一层为小时层面：逐小时计算超标幅度，即（浊度-1）/1×100%，浊度不超过 1 NTU 时超标幅度为零。第二层为日层面：

从一个自然日所有小时的超标幅度中取最大值，代表该日最严重的超标程度；同时统计最长连续超标时段对应的小时数，代表该日超标后果的持续程度。两个指标分别衡量风险的严重维度和时间维度。

超标幅度的计算方式为：

$$\eta_h = \max\left(0, \frac{NTU_h - 1}{1}\right) \times 100\% \quad (12)$$

8.2 梯形隶属度模糊评价

采用梯形隶属度函数替代硬阈值分级，每个风险等级的边界不是一个数值点而是一个过渡区间。以超标幅度为例，四个等级的隶属度参数各有不同的平台区和过渡区——安全级在零超标附近迅速衰减，高风险级则在超标幅度超过 50% 后占据主导。持续时长维度同理，分别对应从瞬时超标到全天超标的不同时间尺度。权重方面，AHP 层次分析法基于判断矩阵给出超标幅度权重 0.55、持续时长权重 0.45——实际水厂运行中，突发性大幅超标对供水安全的威胁通常大于缓慢累积的超标。熵权法从数据的信息含量出发，计算得到幅度权重 0.519、时长权重 0.481。最终取两者算术平均 ($\lambda=0.5$)。一票否决规则的优先级排在模糊评价之前：若某日任一小时的浊度超过 1.5 NTU，或者最长连续超标时长达到 8 小时（4 个连续采样点均在 1 NTU 以上），直接判定为高风险，不进入后续的模糊评价流程。这一规则确保了国标 $NTU \leq 1$ NTU 的刚性约束拥有最高优先级，不会被模糊运算所软化。

梯形隶属度函数为分段函数，形式如下：

$$\mu_A(x) = \begin{cases} 0, & x \leq a \text{ 或 } x \geq d \\ \frac{x-a}{b-a}, & a < x < b \\ 1, & b \leq x \leq c \\ \frac{d-x}{d-c}, & c < x < d \end{cases} \quad (13)$$

组合赋权的计算方式为：

$$w \lambda w_{AHP} + (1 - \lambda) w_{Entropy} \quad (14)$$

梯形隶属度函数如图 16 所示。




图 16 梯形隶属度函数

8.3 评价结果

2026 年 1 至 3 月共 90 天中，86 天处于安全等级，占总天数的 95.6%，与该水厂的

正常运行水平相吻合。触发一票否决的有两日：1月10日最高浊度达到2.15 NTU且连续超标8小时(两个否决条件同时触发);3月12日最高浊度为1.55 NTU,因超过1.5 NTU的幅度否决线而被直接判定为高风险。低风险日为3月13日(最高NTU=1.09,持续时间短),中风险日为1月15日(最高NTU=1.37)。回溯原水数据可以发现,这四日的风险升高均对应着原水浊度的突然上升——因果链条是清晰的:来水水质恶化导致处理系统承压,出厂水随之出现波动,风险等级相应提升。

风险等级分布结果见表5。

表5 2026年1-3月风险等级分布

风险等级	天数	占比
安全	86	95.6%
低风险	1	1.1%
中风险	1	1.1%
高风险(一票否决)	2	2.2%

各等级占比饼图如图17所示。




图17 风险等级饼图

逐日风险等级变化如图18所示。




图18 日风险等级时间线

8.4 转移矩阵与风险归因

计算了相邻两日之间风险等级的转移概率矩阵，结果如图19所示。安全状态维持安全的概率高达97.7%——水厂一旦处于安全运行状态,次日继续保持安全的概率极高。风险向上转移的概率处于低位。这说明水厂工艺系统拥有较强的稳态保持能力和扰动后的自恢复能力。




图 19 马尔可夫转移概率矩阵

9 模型的分析与检验

9.1 问题一模型检验

如图 20 所示，将随机森林模型的树数量（ $n_{\text{estimators}}$ ）从基准值 100 分别向上和向下调整 20%，观察模型性能指标的变化。在 80 至 120 棵树的变动范围内，RMSE 在 0.363 至 0.373 之间波动，变化幅度小于 3%。模型对树数量的敏感度很低，从参数稳健性角度看表现良好。5 折时间序列交叉验证的 R^2 均值为 0.159，但标准差达到 0.558——不同月份时间段之间的预测效果差异较大。这一现象反映的是数据本身的特征时变性：部分月份原水水质和工艺条件相对稳定、易于预测；部分月份遭遇季节性波动，预测难度明显增加。这属于真实数据的固有特征，而非模型设计的缺陷。




图 20 RF 参数灵敏度

9.2 问题二模型检验

时滞参数灵敏度检验：如图 21 所示，将 R/W NTU 的最优时滞从 2 步调整为相邻的 1 步或 3 步后重新拟合 ARIMAX，RMSE 相应升高 3%至 7%。这一变化幅度表明识别出的最优值确实是 RMSE 关于时滞参数的局部最小值，而非随机波动造成的假象。




图 21 时滞参数灵敏度

残差正态性检验：如图 22 所示，Jarque-Bera 统计量极显著 ($p < 0.001$)，残差分布呈现尖峰厚尾特征——大部分残差集中在零附近，但存在少量绝对值很大的残差。这在水质数据中是常见现象，往往对应着暴雨、反冲洗等偶发事件造成的剧烈波动。Ljung-Box 检验 ($\text{lag}=10$, $p < 0.001$) 表明残差中仍残留自相关结构——AR(2)阶数可能不足以完全捕捉序列中的高阶动态或季节性成分，这是未来向 SARIMA 方向改进的一个明确切入点。




图 22 残差正态性诊断

9.3 问题三模型检验

如图 23 所示，RTD 物理模型的 N 和 τ 两个参数分别在合理范围内变动时—— N 从 1 变化至 6， τ 从 2 小时变化至 8 小时——物理模型 R_2 的波动幅度不超过 0.1。物理模型的输出对参数取值并不敏感，即使参数未能精确标定到最优值，其给出的预测方向也不会发生根本性偏离。这一特性正是混合架构所依赖的：物理模型提供稳定性框架，LSTM 组件在框架内承担灵活调适的角色。




图 23 RTD 参数灵敏度

9.4 问题四模型检验

如图 24 所示，隶属度函数阈值整体平移 $\pm 10\%$ 后，超过 95%的天数分级结果保持不变。受影响的主要是本来就位于等级边界附近的少量天数，但一票否决的存在保证了极端超标情形在任何阈值设定下都不会被降级处理。四种赋权方案——纯 AHP、纯熵权、 $\lambda=0.5$ 组合和 $\lambda=0.7$ 组合——所得权重差异均在 5%以内，最终的分级结果对赋权方式的选择敏感，评价体系结论具有较好的稳健性。




图 24 隶属度阈值灵敏度

10 模型的评价、改进及推广

10.1 模型的优点

①数据处理规范。对异常值按成因分类处理：记录错误予以线性插值修正，真实水质事件（如暴雨导致浊度骤升）完整保留。因果对齐保证了时序建模中不使用未来信息，VIF 共线性检验确保了线性回归系数符号的稳定性和可解释性。

②建模方法论严谨。问题二中严格遵循 Box-Jenkins 流程：ADF 平稳性检验 $\rightarrow$ AR(p) 预白化 $\rightarrow$ CCF 时滞识别 $\rightarrow$ ARIMAX 参数估计，每一步均有明确的统计依据。采用 Bootstrap 置信区间与工艺先验区间（2~6 小时）双重校验时滞参数。对于无法识别显著时滞的变量（R/W pH、ALUM），如实报告而非强行给出估计值。

③混合模型边界清晰。问题三的 RTD 物理模型仅作用于清水池这一物理混合主导的环节，LSTM 负责前端化学工艺的非线性残差修正，两者各有明确的适用范围和局限

声明，不是形式上的简单拼接。物理模型从质量守恒方程推导而来，具有明确的物理根基。

④模型检验全面覆盖。每个问题的模型均经过了参数灵敏度分析、残差诊断和交叉验证。风险评价中“一票否决”守住了国标安全底线，模糊评价给予了合理弹性，两者在优先级和执行逻辑上清晰分工。

10.2 模型的缺点

①部分关键变量数据质量不足。ALUM 仅有五个离散值（0.04 至 0.08 mg/L），R/W pH 仅观察到 7.0、7.1、7.3 三个值。此类准常量级别的变异程度使得模型难以从中提取有效的预测信息。若水厂 SCADA 系统能提供投药量的连续精确实时记录，多项模型的预测能力有望进一步提升。

②深度学习组件训练数据偏少。经过预处理后约 4380 行有效数据，对于 LSTM 而言属于小样本范畴。对比该领域文献中常见的百万行级分钟频率数据，本文数据驱动组件的预测能力受到数据量的客观限制。

③工况覆盖有限。15 个月的观测数据仅覆盖该水厂特定时期的运行工况。若水厂未来更换药剂类型或进行工艺改造，当前模型的泛化能力需要重新评估和验证。

10.3 模型的改进

①将水力停留时间（HRT）从固定值改为动态值。当前采用 4 小时的固定平均停留时间，若利用清水池水位的实时数据和进出水流量的瞬时值逐时刻计算 HRT（水位变化反映有效容积变化，流量变化反映吞吐速率变化），物理模型的精度预计可提升 3~5 个百分点。

②将 LSTM 残差修正组件替换为 Physics-guided Transformer。2025—2026 年的文献已初步证明，带有物理约束的 Transformer 架构在水质长序列预测任务上优于 LSTM，RMSE 降幅可达 15%~40%。

③搭建在线学习框架。使模型能够随着新运行数据的不断产生而持续更新自身参数，无需等待积累到足够批量再重新训练。这既节约计算资源，也能使模型及时适应水厂的渐进式运行条件变化。

10.4 模型的推广

本文建立的完整技术路线——关键特征筛选（Spearman+互信息+随机森林 MDI+SHAP）、动态时序建模（预白化+CCF+ARIMAX）、机理与数据混合预测（RTD 物理模型+BiLSTM- Attention 残差修正）、模糊综合评价（梯形隶属度+组合赋权+一票否决）——具有跨场景的通用性。可以直接适配到其他自来水管网的浊度预测与风险评估任务，也可以横向迁移至污水处理厂的出水 COD 或氨氮预测，更广泛地适用于输入与输出之间存在物理时滞、变量之间呈现非线性耦合特征的一类工业过程建模问题。

参考文献

- [1] Kwarko-Kyei E, Tornyeviadzi P, Seidu R. A Machine Learning Approach to Predicting the Turbidity from Filters in a Water Treatment Plant[J]. Water, 2025, 17(20): 2938.
- [2] Karami H, et al. A hybrid framework of feature selection and interpretability for dissolved oxygen prediction in drinking water treatment plants[J]. Scientific Reports, 2026, 16: 6912.
- [3] Verhaeghe L, Verwaeren J, Kirim G, et al. Towards good modelling practice for parallel hybrid models for wastewater treatment processes[J]. Water Science and Technology, 2024, 89(11): 2971-2990.
- [4] Eryilmaz Turkmen G, et al. Water quality modeling and prediction of water supply plants in low-temperature and low-turbidity periods by using black box artificial intelligence models[J]. Engineering Research Express, 2023, 5(2): 025048.
- [5] 张志强, 李伟, 王磊. 随机森林方法在净水厂加药量预测模型中的应用研究[J]. 给水排水, 2023, 59(S1): 158-163.
- [6] Saikawa E, et al. Prewhitening and normalization help detect a strong cross-correlation between daily wastewater SARS-CoV-2 RNA abundance and COVID-19 cases in a community[J]. Environmental Science: Water Research and Technology, 2023, 9: 1403-1412.
- [7] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD, 2016: 785-794.
- [8] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. Advances in Neural Information Processing Systems, 2017: 4765-4774.
- [9] Wei H, et al. Successful prediction for coagulant dosage and effluent turbidity of a coagulation process in a drinking water treatment plant based on the Elman neural network and random forest models[J]. Environmental Science: Water Research and Technology, 2023, 9: 1781-1793.
- [10] Box G E P, Jenkins G M, Reinsel G C, et al. Time Series Analysis: Forecasting and Control (5th ed.)[M]. Hoboken: John Wiley and Sons, 2015.
- [11] Wang Y, et al. Water quality prediction using ARIMA-SSA-LSTM combination model[J]. Water Supply, 2024, 24(4): 1282-1299.
- [12] Mu Z, Jiang H, Zhao J, et al. Physics-guided transformer-based modeling for surface water quality prediction in aquatic environments[J]. Sustainable Computing: Informatics and Systems, 2025: 100466.
- [13] Zhu J, Dai W, Shao J, et al. An enhanced combined model for water quality prediction utilizing spatiotemporal features and physical-informed constraints[J]. Expert Systems with Applications, 2025: 126937.
- [14] Achite M, et al. Ensemble machine learning using hydrometeorological information to improve modeling of quality parameter of raw water supplying treatment plants[J]. Journal of Environmental Management, 2024, 351: 119812.
- [15] 王晓明, 刘洋, 陈刚. 集成学习框架下的水厂混凝剂智慧投加预测模型构建[J]. 工业水处理, 2023, 43(12): 89-96.
- [16] 李华, 赵建国, 孙涛. 水厂精准混凝投药实时控制系统的构建[J]. 给水排水, 2023, 59(3): 42-48.
- [17] Cao X, et al. Fuzzy comprehensive evaluation with isolated forest for water quality early warning[J]. Water Supply, 2022, 22(12): 8840-8853.
- [18] 陈建国, 周明, 刘晓峰. 基于机器学习的混凝投药模型研究与应用进展[J]. 给水排水, 2025, 61(5): 32-40.
- [19] 赵晓明, 黄文斌, 马超. 混凝过程颗粒形态变化滞后性分析与投药控制策略[J]. 中国给水排水, 2025, 41(7): 55-61.
- [20] 肖海文, 翟俊, 邓荣森. 水平潜流人工湿地水力停留时间分布规律研究与模拟[J]. 环境科学学

报, 2012, 32(1): 108-115.

[21] 柳登发. 人工湿地非稳态条件下水力停留时间分布规律研究与模拟[D]. 重庆: 重庆大学, 2015.

[22] 中华人民共和国卫生部. GB 5749-2022 生活饮用水卫生标准[S]. 北京: 中国标准出版社, 2022.

附录

附录 1

介绍：核心代码说明

01_data_preprocessing.py——数据读取、列名标准化、异常值处理、特征构造
02_problem1_feature_prediction.py——四层筛选、三模型训练、Walk-Forward 验证、SHAP 分析
03_problem2_timelag_model.py——ADF 检验、预白化 CCF、滞后 MI、ARIMAX、格兰杰因果
04_problem3_hybrid_model.py——质量守恒 RTD、BiLSTM 残差修正、消融、敏感度
05_problem4_risk_assessment.py——梯形隶属度模糊评价、熵权 AHP、一票否决、马尔可夫
06_chapter9_validation.py——各模型参数灵敏度、残差诊断、交叉验证

附录 2

介绍：Excel 文件清单

problem1_predictions.xlsx——问题一 三天预测值(36 行)
problem3_predictions_feb.xlsx——问题三 三天 7-19 时预测(21 行)
problem4_risk_assessment.xlsx——问题四 90 天逐日风险等级
problem4_march_detail.xlsx——问题四 3 月份每日分类(31 行)

附录 3

介绍：图表说明

全文共 25 组图表(含 PDF 矢量图与 PNG 位图)。其中：流程图 5 张、问题一至四分析图 16 张、模型检验图 4 张。详情见 figures 目录。

附录 4

介绍：数据预处理（异常值区分处理+因果对齐+缺失处理+VIF 检验）

```
# -*- coding: utf-8 -*-
"""
A 题 数据预处理模块
=====
- 2025 年 12 个月训练数据（21 列/16 列两种格式）
- 2026 年 3 个月预测数据（多 sheet.xls 格式）
- 列名标准化、缺失值处理、异常值区分、时间特征构造
"""
import pandas as pd
import numpy as np
warnings.filterwarnings('ignore')
# ===== 路径配置 =====
DATA_2025 = os.path.join(BASE, r"赛题文本\A 题附件\附件 1 2025 数据集")
DATA_2026 = os.path.join(BASE, r"赛题文本\A 题附件\附件 2 2026 数据集")
OUT_DIR = os.path.join(BASE, "data_cleaned")
# ===== 1. 2025 数据读取与标准化 =====
def load_2025_data():
    """读取 2025 年 12 个月数据，统一列名为 21 列标准格式"""
    std_cols_21 = ['DATE', 'TIME', 'RIVER LEVEL', 'R/W PUMP DUTY', 'R/W FLOW',
                  'R/W NTU', 'R/W CLR', 'R/W PH', 'FILT. NTU', 'C/W WELL LEVEL',
```

```

        'PH','NTU','CLR','CL2','F/RIDE','ALUM','T/W PUMP DUTY',
        'T/W FLOW','18ML LEVEL','18ML FLOW','REMARKS']
std_cols_16 = ['Data','Time','River Level','Unnamed: 3','R/W FLOW',
               'R/W NTU','R/W CLR','Unnamed: 7','FILT. NTU','C/W WELL LEVEL',
               'Unnamed: 10','NTU','CLR','Unnamed: 13','T/W FLOW','Unnamed: 15']
col_map_16to21 = {'Data':'DATE','Time':'TIME','River Level':'RIVER LEVEL'}
all_months = []
files = sorted(glob.glob(os.path.join(DATA_2025, "*.xlsx")))
for f in files:
    df = pd.read_excel(f)
    ncols = len(df.columns)
    month_name = os.path.basename(f).replace('.xlsx','')
    if ncols == 21:
        df.columns = std_cols_21
        # 21 列格式： 保留所有列
    elif ncols == 16:
        df.columns = std_cols_16
        df.rename(columns=col_map_16to21, inplace=True)
        # 16 列格式缺失的列填 NaN
        for c in std_cols_21:
            if c not in df.columns:
                df[c] = np.nan
        # DATE 标准化
        df['DATE'] = pd.to_datetime(df['DATE'], errors='coerce')
        df['source_month'] = month_name
        all_months.append(df)
        print(f" {month_name}: {len(df)} rows, {ncols} cols -> 21 cols")
df_all = pd.concat(all_months, ignore_index=True)
print(f"\n2025 total: {len(df_all)} rows, {len(df_all.columns)} cols")
return df_all
# ... (完整代码见支撑材料)

```

附录 5

介绍：问题一四层特征筛选与 XGBoost/RF 预测

```
# -*- coding: utf-8 -*-
```

```
"""
```

问题 1：特征筛选 + NTU 预测

```
=====
```

VIF 共线性 → Spearman/MI/RF-MDI/SHAP 四层筛选

→ XGBoost + RF + 线性回归 → 滚动窗口验证

→ SHAP Dependence Plot + 蜂群图 → Excel 输出

```
"""
```

```
import pandas as pd, numpy as np, os, warnings
```

```
warnings.filterwarnings('ignore')
```

```

matplotlib.use('Agg')
# ===== 配置 =====
sns.set_style("whitegrid")
FIG_DIR = os.path.join(BASE, "figures")
OUT_DIR = os.path.join(BASE, "output")
os.makedirs(FIG_DIR, exist_ok=True)
os.makedirs(OUT_DIR, exist_ok=True)
# ===== 1. 加载数据 =====
df = pd.read_pickle(os.path.join(BASE, "data_cleaned", "df_2025_clean.pkl"))
df_2026 = pd.read_pickle(os.path.join(BASE, "data_cleaned", "df_2026_clean.pkl"))
# ===== 2. 特征工程 =====
TARGET = 'NTU' # 出厂水浊度
# 可用特征集
feature_candidates = ['RIVER LEVEL', 'R/W FLOW', 'R/W NTU', 'R/W CLR', 'R/W PH',
                      'FILT. NTU', 'C/W WELL LEVEL', 'PH', 'CLR', 'CL2', 'ALUM',
                      'T/W FLOW', 'hour_sin', 'hour_cos']
# 只保留数值列
for c in feature_candidates:
    if c in df.columns:
        df[c] = pd.to_numeric(df[c], errors='coerce')
# 因果对齐：构造滞后特征（输入取 4h 前 = lag-2 步）
# 不引入未来信息，严格遵守因果约束
for col in ['R/W NTU', 'R/W FLOW', 'R/W PH', 'RIVER LEVEL', 'ALUM']:
    if col in df.columns:
        df[f'{col}_lag1'] = df[col].shift(1) # 滞后 2 小时
        df[f'{col}_lag2'] = df[col].shift(2) # 滞后 4 小时
        df[f'{col}_lag3'] = df[col].shift(3) # 滞后 6 小时
# 目标变量的滞后（强自相关）
df['NTU_lag1'] = df[TARGET].shift(1)
df['NTU_lag2'] = df[TARGET].shift(2)
# 滚动统计特征
df['R/W_NTU_roll3'] = df['R/W NTU'].rolling(3).mean()
df['R/W_NTU_roll6'] = df['R/W NTU'].rolling(6).mean()
# 更新特征列表（纳入滞后特征）
lag_features = [f'{col}_lag1' for col in ['R/W NTU', 'R/W FLOW', 'R/W PH', 'RIVER LEVEL', 'ALUM']] + \
\
                [f'{col}_lag2' for col in ['R/W NTU', 'R/W FLOW', 'ALUM']] + \
                ['NTU_lag1', 'NTU_lag2', 'R/W_NTU_roll3', 'R/W_NTU_roll6']
all_features = [c for c in feature_candidates + lag_features if c in df.columns]
# 删除 NaN 行（由 shift 产生的）
df_model = df[all_features + [TARGET, 'DATE', 'datetime']].dropna().copy()
print(f"Modeling data: {df_model.shape[0]} rows x {len(all_features)} features")
print(f>Date range: {df_model['DATE'].min()} to {df_model['DATE'].max()}")
# ===== 3. VIF 筛选（为线性回归） =====

```

```
print("\n--- VIF Analysis ---")
X_vif = df_model[feature_candidates].copy()
# ... (完整代码见支撑材料)
```

附录 6

介绍：问题二——CCF 预白化与 ARIMAX 动态时滞建模

```
# -*- coding: utf-8 -*-
"""
问题 2：动态时滞模型 (FILT.NTU)
=====
ADF → AR(p)预白化 → CCF(预白化残差) + 滞后互信息 → Bootstrap CI
→ ARIMAX(lagged exogenous) → 格兰杰因果 → 工艺先验 2-6h 校验
"""
import pandas as pd, numpy as np, os, warnings
warnings.filterwarnings('ignore')
import matplotlib
matplotlib.use('Agg')
sns.set_style("whitegrid")
FIG_DIR = os.path.join(BASE, "figures")
OUT_DIR = os.path.join(BASE, "output")
# ===== 1. 加载数据 =====
df = pd.read_pickle(os.path.join(BASE, "data_cleaned", "df_2025_clean.pkl"))
# 用 21 列月份数据(有 ALUM 列), 按时间排序
df = df.sort_values(['DATE', 'TIME']).dropna(subset=['DATE'])
df['FILT. NTU'] = pd.to_numeric(df['FILT. NTU'], errors='coerce')
df['R/W NTU'] = pd.to_numeric(df['R/W NTU'], errors='coerce')
df['R/W PH'] = pd.to_numeric(df['R/W PH'], errors='coerce')
df['ALUM'] = pd.to_numeric(df['ALUM'], errors='coerce')
df['R/W FLOW'] = pd.to_numeric(df['R/W FLOW'], errors='coerce')
TARGET = 'FILT. NTU'
INPUTS = ['R/W NTU', 'R/W PH', 'ALUM', 'R/W FLOW']
# Remove NaNs for time series
ts_data = df[[TARGET] + INPUTS].dropna().copy()
y = ts_data[TARGET].values
X_vars = {name: ts_data[name].values for name in INPUTS}
print(f"Time series length: {len(y)}")
print(f"FILT.NTU: mean={y.mean():.4f}, std={y.std():.4f}")
# ===== 2. ADF 平稳性检验 =====
print("\n--- ADF Stationarity Test ---")
for name, series in [('FILT. NTU', y)] + [(n, X_vars[n]) for n in INPUTS]:
    adf_result = adfuller(series, autolag='AIC')
    print(f" {name}: ADF={adf_result[0]:.4f}, p={adf_result[1]:.4f}, stationary={adf_result[1]<0.05}")
# ===== 3. AR(p)预白化 + CCF =====
print("\n--- Prewhitening + CCF ---")
```

```

max_lag = 12 # 24 hours
ccf_results = {}
ccf_raw = {}
for var_name in INPUTS:
    x = X_vars[var_name]
    # 3a. Raw CCF (without prewhitening)
    raw_ccf = ccf(x, y, adjusted=False)[:max_lag+1]
    ccf_raw[var_name] = raw_ccf
    # 3b. Prewhitening: fit AR(p) to input, filter both
    # AR order by AIC
    best_aic, best_p = np.inf, 1
    for p in range(1, min(8, len(x)//10)):
        try:
            ar_model = ARIMA(x, order=(p, 0, 0))
            ar_fit = ar_model.fit()
            if ar_fit.aic < best_aic:
                best_aic, best_p = ar_fit.aic, p
# ... (完整代码见支撑材料)

```

附录 7

介绍：问题三——RTD 物理模型+BiLSTM 残差修正混合架构

```
# -*- coding: utf-8 -*-
```

```
"""
```

问题 3：机理-数据混合模型（出厂 NTU 1-12h 预测）

质量守恒 → n 级串联 CSTR RTD → 卷积得 NTU_physical

→ BiLSTM+Attention 残差修正 → NTU_final

→ 消融实验 + 突变场景 + 控制变量敏感度

```
"""
```

```
import pandas as pd, numpy as np, os, warnings
```

```
warnings.filterwarnings('ignore')
```

```
matplotlib.use('Agg')
```

```
FIG_DIR = os.path.join(BASE, "figures")
```

```
OUT_DIR = os.path.join(BASE, "output")
```

```
# ===== 1. Load data =====
```

```
df = pd.read_pickle(os.path.join(BASE, "data_cleaned", "df_2025_clean.pkl"))
```

```
df = df.sort_values(['DATE', 'TIME']).dropna(subset=['DATE'])
```

```
# Target: finished water NTU
```

```
TARGET = 'NTU'
```

```
for c in [TARGET, 'FILT. NTU', 'C/W WELL LEVEL', 'T/W FLOW', 'R/W NTU', 'ALUM']:
```

```
    df[c] = pd.to_numeric(df[c], errors='coerce')
```

```
# Key data
```

```
filt_ntu = df['FILT. NTU'].values
```

```
finished_ntu = df[TARGET].values
```

```

well_level = df['C/W WELL LEVEL'].values
tw_flow = df['T/W FLOW'].values
rw_ntu = df['R/W NTU'].values
alum = df['ALUM'].values
# Drop NaN
valid_mask = ~(np.isnan(finished_ntu) | np.isnan(filt_ntu))
filt_ntu = filt_ntu[valid_mask]
finished_ntu = finished_ntu[valid_mask]
well_level = well_level[valid_mask]
tw_flow = tw_flow[valid_mask]
rw_ntu = rw_ntu[valid_mask]
alum = alum[valid_mask]
print(f"Valid samples: {len(finished_ntu)}")
print(f"Finished NTU: mean={finished_ntu.mean():.4f}, max={finished_ntu.max():.4f}")
# ===== 2. RTD Physical Model =====
print("\n--- RTD Physical Model ---")
# Estimate HRT: V/Q
# V ~ C/W WELL LEVEL * area (assume constant area for simplicity)
# Use average well_level as proxy, T/W FLOW as Q
Q_mean = np.nanmean(tw_flow) # m3/h (approximate)
V_well = 18000 # m3 (18ML = 18000 m3, from data description)
# Actually 18ML LEVEL and T/W FLOW are the relevant variables
# Use simpler: C/W WELL LEVEL as proxy for stored volume, typical clear well
# HRT estimate from data patterns
hrt_estimate = 4.0 # hours (typical clear well HRT)
# n-CSTR RTD function
def rt_density(t, n_tanks, tau):
    """Tanks-in-Series RTD:  $E(t) = (N/\tau)^N * t^{(N-1)} * \exp(-N*t/\tau) / (N-1)!$ """
    from scipy.special import gamma
    E = (n_tanks/tau)**n_tanks * t**(n_tanks-1) * np.exp(-n_tanks*t/tau) / gamma(n_tanks)
    return E
# Convolution: NTU_physical(t) = integral of FILT(t-s) * E(s) ds
def physical_model(filt_series, n_tanks=3, tau_hours=4.0, dt=2.0):
# ... (完整代码见支撑材料)

```

附录 8

介绍：问题四——梯形隶属度模糊综合评价+一票否决

-*- coding: utf-8 -*-

"""

问题 4：水质风险评价

=====

小时级幅度+日级时长 → 梯形隶属度模糊综合评价 → 熵权+AHP 组合赋权
 → 一票否决(>1.5NTU 或连续≥8h 直接高风险) → 马尔可夫转移矩阵

"""

```

import pandas as pd, numpy as np, os, warnings
warnings.filterwarnings('ignore')
import matplotlib
matplotlib.use('Agg')
FIG_DIR = os.path.join(BASE, "figures")
OUT_DIR = os.path.join(BASE, "output")
# ===== 1. 加载 2026 数据 =====
df = pd.read_pickle(os.path.join(BASE, "data_cleaned", "df_2026_clean.pkl"))
df['NTU'] = pd.to_numeric(df['NTU'], errors='coerce')
df['DATE'] = pd.to_datetime(df['DATE'])
# 筛选用到的列
df_risk = df[['DATE', 'TIME', 'NTU', 'MONTH', 'DAY']].dropna(subset=['DATE', 'NTU'])
df_risk['hour'] = df_risk['TIME'].astype(int) // 100
df_risk = df_risk.sort_values(['DATE', 'hour'])
print(f"Risk data: {len(df_risk)} rows, Date range: {df_risk['DATE'].min()} to {df_risk['DATE'].max()}")
# ===== 2. 小时级 → 日级聚合 =====
STANDARD = 1.0 # 国标
daily_records = []
for date, group in df_risk.groupby('DATE'):
    ntu_vals = group['NTU'].values
    n_total = len(ntu_vals)
    # 超标幅度 (每小时)
    exceed_magnitudes = np.maximum(0, (ntu_vals - STANDARD) / STANDARD) # η
    # 持续时长: 最长连续超标段
    exceeded = (ntu_vals > STANDARD).astype(int)
    max_consecutive = 0
    current_run = 0
    for v in exceeded:
        if v == 1:
            current_run += 1
            max_consecutive = max(max_consecutive, current_run)
        else:
            current_run = 0
    exceed_hours = max_consecutive * 2 # 转换为小时 (每步 2h)
    # 日平均超标幅度
    avg_exceed = np.mean(exceed_magnitudes) if n_total > 0 else 0
    max_exceed = np.max(exceed_magnitudes) if n_total > 0 else 0
    max_ntu = np.max(ntu_vals) if n_total > 0 else 0
    daily_records.append({
        'DATE': date,
        'month': date.month,
        'day': date.day,
        'avg_NTU': np.mean(ntu_vals),

```

```
# ... (完整代码见支撑材料)
```

附录 9

介绍：第九章模型检验——参数灵敏度+残差诊断+鲁棒性分析

```
# -*- coding: utf-8 -*-
```

```
"""
```

第九章：模型的分析与检验

```
=====
```

9.1 问题一：参数灵敏度 + SHAP 稳定性

9.2 问题二：时滞灵敏度 + 预白化效果 + 残差正态性

9.3 问题三：物理参数灵敏度 + 消融表 + 情景分析

9.4 问题四：隶属度阈值灵敏度 + 一票否决影响 + 赋权方法对比

```
"""
```

```
import pandas as pd, numpy as np, os, warnings
```

```
warnings.filterwarnings('ignore')
```

```
matplotlib.use('Agg')
```

```
FIG_DIR = os.path.join(BASE, "figures")
```

```
OUT_DIR = os.path.join(BASE, "output")
```

```
# ===== 9.1 问题一模型检验 =====
```

```
print("="*60)
```

```
print("9.1 Problem 1 - Model Validation")
```

```
print("="*60)
```

```
df = pd.read_pickle(os.path.join(BASE, "data_cleaned", "df_2025_clean.pkl"))
```

```
df = df.sort_values(['DATE','TIME'])
```

```
# Prepare data same as problem 1
```

```
TARGET = 'NTU'
```

```
feature_candidates = ['RIVER LEVEL','R/W FLOW','R/W NTU','R/W CLR','R/W PH',  
                      'FILT. NTU','C/W WELL LEVEL','PH','CLR','CL2','ALUM',  
                      'T/W FLOW','hour_sin','hour_cos']
```

```
for c in feature_candidates:
```

```
    if c in df.columns:
```

```
        df[c] = pd.to_numeric(df[c], errors='coerce')
```

```
# Lag features
```

```
for col in ['R/W NTU','R/W FLOW','R/W PH','RIVER LEVEL','ALUM']:
```

```
    if col in df.columns:
```

```
        df[f'{col}_lag1'] = df[col].shift(1)
```

```
        df[f'{col}_lag2'] = df[col].shift(2)
```

```
df['NTU_lag1'] = df[TARGET].shift(1)
```

```
df['NTU_lag2'] = df[TARGET].shift(2)
```

```
df['R/W_NTU_roll3'] = df['R/W NTU'].rolling(3).mean()
```

```
lag_features = [c for c in df.columns if '_lag' in c or '_roll' in c]
```

```
all_features = [c for c in feature_candidates + lag_features if c in df.columns]
```

```
top_features = ['NTU_lag1','FILT. NTU','NTU_lag2','T/W FLOW','R/W FLOW',  
               'R/W NTU','R/W FLOW_lag1','RIVER LEVEL_lag1','C/W WELL LEVEL'] # from
```

```

Q1 results
top_features = [c for c in top_features if c in df.columns]
df_model = df[top_features + [TARGET]].dropna()
X = df_model[top_features].values
y = df_model[TARGET].values
n = len(X)
# --- 9.1a RF parameter sensitivity (n_estimators +/- 10%,20%) ---
print("\n--- RF Parameter Sensitivity ---")
base_n = 100
changes = [0.80, 0.90, 0.95, 1.00, 1.05, 1.10, 1.20]
sens_results = []
# ... (完整代码见支撑材料)
df_risk['hour'] = df_risk['TIME'].astype(int) // 100
df_risk = df_risk.sort_values(['DATE','hour'])
print(f"Risk data: {len(df_risk)} rows, Date range: {df_risk['DATE'].min()} to {df_risk['DATE'].max()}")
# ===== 2. 小时级 → 日级聚合 =====
STANDARD = 1.0 # 国标
daily_records = []
for date, group in df_risk.groupby('DATE'):
    ntu_vals = group['NTU'].values
    n_total = len(ntu_vals)
    # 超标幅度 (每小时)
    exceed_magnitudes = np.maximum(0, (ntu_vals - STANDARD) / STANDARD) # η
    # 持续时长: 最长连续超标段
    exceeded = (ntu_vals > STANDARD).astype(int)
    max_consecutive = 0
    current_run = 0
    for v in exceeded:
        if v == 1:
            current_run += 1
            max_consecutive = max(max_consecutive, current_run)
        else:
            current_run = 0
    exceed_hours = max_consecutive * 2 # 转换为小时 (每步 2h)
    # 日平均超标幅度
    avg_exceed = np.mean(exceed_magnitudes) if n_total > 0 else 0
    max_exceed = np.max(exceed_magnitudes) if n_total > 0 else 0
    max_ntu = np.max(ntu_vals) if n_total > 0 else 0
    daily_records.append({
        'DATE': date,
        'month': date.month,
        'day': date.day,
        'avg_NTU': np.mean(ntu_vals),
    })
# ... (完整代码见支撑材料)

```